

PageRank y Minería de Grafos Heterogéneos sobre Habilidades Laborales y Mallas Universitarias: Un Enfoque de Analítica Web para la Predicción Salarial y el Diagnóstico de Brechas Formativas

*Note: Sub-titles are not captured in Xplore and should not be used

1st Given Name Surname
dept. name of organization (of Aff.)
name of organization (of Aff.)
City, Country
email address or ORCID

2nd Given Name Surname
dept. name of organization (of Aff.)
name of organization (of Aff.)
City, Country
email address or ORCID

3rd Given Name Surname
dept. name of organization (of Aff.)
name of organization (of Aff.)
City, Country
email address or ORCID

4th Given Name Surname
dept. name of organization (of Aff.)
name of organization (of Aff.)
City, Country
email address or ORCID

5th Given Name Surname
dept. name of organization (of Aff.)
name of organization (of Aff.)
City, Country
email address or ORCID

6th Given Name Surname
dept. name of organization (of Aff.)
name of organization (of Aff.)
City, Country
email address or ORCID

Abstract—This document is a model and instructions for L^AT_EX. This and the IEEEtran.cls file define the components of your paper [title, text, heads, etc.]. *CRITICAL: Do Not Use Symbols, Special Characters, Footnotes, or Math in Paper Title or Abstract.

Index Terms—component, formatting, style, styling, insert

I. INTRODUCCIÓN

En los últimos años, la rápida evolución de la industria tecnológica y los procesos de digitalización han transformado drásticamente la demanda de competencias en el mercado de trabajo. En este contexto, la Analítica Web y la minería de datos no estructurados (Web Content Mining) se han consolidado como herramientas clave para estudiar la dinámica laboral a partir de vacantes publicadas en portales de empleo en línea. Diversas investigaciones han recurrido a técnicas de procesamiento de lenguaje natural y modelos de aprendizaje automático para estructurar ofertas y clasificar compensaciones económicas, empleando de forma paralela el análisis de redes complejas para evaluar la relevancia y conectividad de habilidades técnicas clave dentro del ecosistema laboral.

A pesar de estos avances, persiste una fragmentación metodológica fundamental: la demanda laboral y la oferta académica universitaria suelen investigarse de forma aislada. Por un lado, los postulantes y egresados enfrentan una marcada asimetría de información que les dificulta identificar con precisión qué competencias específicas determinan mejores bandas salariales en el mercado profesional. Por otro lado,

no se dispone de marcos computacionales basados en la web que contrasten directamente los requerimientos salariales con los planes de estudio y sumillas de las universidades. Permanece sin resolver cómo mapear de manera sistemática y automatizada en qué facultades, carreras o asignaturas se adquieren las competencias de mayor impacto estructural, dejando sin cuantificar la brecha formativa entre las aulas universitarias y las demandas reales del mercado.

Para abordar esta brecha, el presente estudio plantea una arquitectura de Analítica Web sustentada en la minería de grafos heterogéneos que articula ofertas laborales, competencias técnicas y programas curriculares universitarios. La metodología contempla la extracción web automatizada de ofertas laborales en el sector tecnológico y de planes de estudio universitarios, normalizando sus descriptores técnicos mediante técnicas de procesamiento de lenguaje natural. Sobre la red heterogénea resultante, se aplican algoritmos de centralidad de enlaces (PageRank y HITS) para ponderar el impacto sistémico de cada competencia, integrando estas métricas en modelos de aprendizaje supervisado para la predicción de bandas salariales y en algoritmos de agrupamiento para clasificar familias de puestos. En paralelo, se formula un índice de cobertura curricular diseñado para evaluar el grado de alineación de las mallas universitarias frente a las habilidades más influyentes y mejor remuneradas del mercado.

Identify applicable funding agency here. If none, delete this.

II. EASE OF USE

III. TRABAJOS RELACIONADOS

La literatura reciente aborda principalmente dos componentes del problema: la relación entre habilidades y salarios, y la correspondencia entre las competencias demandadas por el mercado laboral y la formación universitaria.

En el primer componente, Ji, Sun y Zhu [?] desarrollaron LGDESetNet, un modelo explicable que utiliza un grafo de habilidades para predecir salarios e identificar las combinaciones de competencias con mayor influencia sobre la remuneración. Esta investigación se relaciona con el presente proyecto porque demuestra que las habilidades no deben analizarse como elementos aislados, sino como una red de competencias que se complementan y adquieren distinto valor dentro del mercado laboral. Asimismo, respalda el uso de estructuras de grafos para representar las relaciones entre ofertas, habilidades y salarios. Sin embargo, su análisis se limita al ámbito laboral y no determina si las competencias mejor remuneradas se desarrollan en los programas universitarios.

Desde la perspectiva académica, Kendzia, Linder y Barthelmess [?] compararon la evolución de la demanda de habilidades en inteligencia artificial con la capacidad de respuesta de las universidades suizas. Mediante el análisis de más de 12 millones de ofertas laborales y la información recopilada de 11 instituciones de educación superior, identificaron que la demanda de profesionales especializados aumentó con mayor rapidez que la oferta formativa. Este estudio se relaciona con la presente investigación porque evidencia la existencia de una brecha entre las competencias solicitadas por las empresas y aquellas desarrolladas por las universidades. No obstante, su enfoque presenta la brecha de manera general y no construye una red que permita localizar las carreras, cursos o asignaturas en las que debería fortalecerse cada habilidad.

Ambas investigaciones coinciden en utilizar información del mercado laboral para identificar competencias relevantes, pero analizan partes diferentes del problema. Ji, Sun y Zhu [?] se concentran en determinar cómo las habilidades influyen en los salarios, mientras que Kendzia, Linder y Barthelmess [?] estudian la capacidad de las universidades para responder a los cambios en la demanda laboral. Por tanto, la primera investigación aporta el componente de valoración económica de las habilidades y la segunda aporta el componente de alineación curricular.

A pesar de estos aportes, todavía falta un enfoque que integre ambos componentes dentro de un mismo modelo. El presente proyecto busca cubrir este vacío mediante un grafo heterogéneo que conecte ofertas laborales, habilidades técnicas, bandas salariales, universidades, carreras y asignaturas. Sobre esta red se aplicarán PageRank y HITS para determinar la importancia estructural de las competencias y, posteriormente, medir su presencia en las mallas curriculares. De esta manera, el estudio no solo identificará qué habilidades están asociadas con mejores salarios, sino también dónde se enseñan y cuáles presentan una menor cobertura académica.

Por un lado, Liu et al. [1] analizaron 65 millones de ofertas laborales mediante una red de co-ocurrencia de habilidades y técnicas de centralidad topológica, hallando que las competencias con menor centralidad de cercanía corresponden a perfiles especializados asociados a una mayor prima salarial ($\rho = -0.51$). Este trabajo apoya directamente al proyecto en el componente técnico y predictivo: valida la modelación del mercado laboral mediante grafos de habilidades y fundamenta la hipótesis de que la posición estructural de una competencia en la red incide en la remuneración, sirviendo de base para la extracción de métricas topológicas orientadas a clasificar bandas salariales.

Por otro lado, Ampolu et al. [2] implementaron un sistema basado en procesamiento de lenguaje natural y similitud de coseno para extraer términos clave de sílabos universitarios y contrastarlos contra competencias requeridas por la industria, cuantificando brechas formativas. Este antecedente respalda al proyecto en el componente temático de alineamiento curricular: proporciona el marco conceptual para descomponer planes de estudio y evaluar la cobertura de habilidades. Asimismo, pone en evidencia las limitaciones del cotejo léxico estático, justificando la necesidad de sustituir las listas predefinidas por un grafo dinámico priorizado por algoritmos de prestigio estructural como PageRank y HITS.

De este modo, ambas investigaciones examinan aristas complementarias del problema mediante aproximaciones metodológicas diferenciadas. Mientras Liu et al. [1] aportan la modelación topológica de la red de competencias y su vinculación con los niveles de remuneración, Ampolu et al. [2] ofrecen un esquema funcional para la descomposición y el cotejo de contenidos curriculares. La disparidad entre el análisis de redes complejas a gran escala y la similitud léxica tradicional evidencia que la valorización económica de las habilidades y el diagnóstico de la cobertura universitaria han sido abordados de manera desconectada en la literatura.

Beresewicz, Cherniaev, Mantaj y Pater (2024) estudian el desajuste entre la formación educativa y la demanda del mercado laboral usando ofertas de empleo en línea. Recolectaron unos 40 millones de ofertas en Polonia (2017–2019) y extrajeron ocupaciones, calificaciones y habilidades apoyándose en las clasificaciones oficiales ESCO e ISCED-F, con diccionarios de sinónimos y lematización. Compararon esa demanda con la oferta de trabajadores, estimada mediante una encuesta a más de 16 mil personas, usando índices de cumplimiento estructural. Encontraron que el mayor desajuste se da en las habilidades específicas de cada puesto y el menor entre regiones geográficas, lo que indica que la brecha se concentra en competencias concretas. Sin embargo, el lado de la oferta se estima con una encuesta y no con los planes de estudio, y el emparejamiento de texto se basa en diccionarios, limitación que los propios autores reconocen.

Decorte et al. (2025) abordan la extracción de habilidades en ofertas laborales, cuyos métodos más avanzados dependen de modelos de lenguaje grandes, costosos y lentos. Como alternativa proponen ConTeXT-match, un bi-encoder con aprendizaje contrastivo y atención a nivel de token, diseñado para

clasificar habilidades entre miles de etiquetas posibles del catálogo ESCO. Además presentan Skill-XL, un benchmark con anotaciones exhaustivas a nivel de oración, y JobBERT V2, un modelo que normaliza títulos de puesto a partir de las habilidades extraídas. Según los autores, el enfoque alcanza resultados de vanguardia con un modelo liviano y escalable. Su alcance se limita al texto de las ofertas: tratan las habilidades como etiquetas aisladas, sin medir su importancia, su relación con el salario ni su vínculo con la formación universitaria.

A diferencia de los antecedentes, esta propuesta integra demanda laboral y oferta formativa en un grafo heterogéneo donde la habilidad conecta ofertas con asignaturas, carreras y universidades, usando los planes de estudio y no una encuesta. Sobre ese grafo, PageRank y HITS miden el impacto sistémico de cada habilidad, y esas métricas alimentan modelos de predicción de bandas salariales y de agrupamiento de puestos. Finalmente, un índice de cobertura curricular permite diagnosticar la brecha a nivel de asignatura y carrera, ponderada por la influencia y la remuneración de cada habilidad, y todo se presenta en un dashboard integral.

IV. METODOLOGÍA

La metodología se organiza en una arquitectura secuencial de ocho etapas.

A. Extracción web de ofertas laborales

Se recolectarán ofertas laborales del sector tecnológico publicadas en portales de empleo en línea de acceso público, como Computrabajo e Indeed en sus versiones para Perú. La extracción se implementará en Python con las bibliotecas *requests* y *BeautifulSoup* para páginas estáticas, y con *Playwright* o *Selenium* para portales que cargan su contenido de forma dinámica. Las consultas de búsqueda se construirán a partir de una lista de palabras clave asociadas a roles tecnológicos (por ejemplo, desarrollo de software, ciencia de datos, ingeniería de datos, DevOps y ciberseguridad), con el fin de delimitar el dominio de estudio.

Dado que los portales retiran las ofertas de la vista pública al vencer su periodo de vigencia, no es posible reconstruir a posteriori el histórico completo de vacantes. Por ello, la recolección se dividirá en dos fases. En la fase retrospectiva, el primer barrido capturará las ofertas aún activas cuya fecha de publicación se ubique dentro de los [30] días previos, lo que permite disponer de un historial inicial sin esperar. En la fase prospectiva, el barrido se repetirá cada [3–4] días durante [7] semanas mediante ejecución programada, con el fin de captar las ofertas nuevas y registrar cuándo dejan de estar visibles. El periodo de estudio se definirá por la fecha de publicación de cada oferta, y no por la fecha del barrido, y abarcará desde [28 de septiembre] hasta el [1 de noviembre]. Dado que la fase retrospectiva solo incluye las ofertas que siguen activas al momento del primer barrido, sobrerrepresenta las vacantes de mayor duración; este sesgo se documentará como limitación del estudio y podrá evaluarse comparando ambas fases.

Para cada vacante se almacenarán el título del puesto, la empresa, la descripción completa, la ubicación, la modalidad

de trabajo, el nivel de experiencia requerido, el rango salarial declarado, la fecha de publicación y la URL de origen, además de tres variables de control: las fechas del primer y del último barrido en que la oferta fue observada (*first_seen* y *last_seen*) y la fase de captura (*origen*: retrospectiva o prospectiva). La recolección respetará las directivas *robots.txt* y los términos de uso de cada portal, e incluirá pausas entre solicitudes para evitar sobrecargar los servidores. Cada registro se guardará sin modificaciones (datos crudos) en formato JSON, junto con la marca temporal de extracción, de modo que el proceso pueda auditarse y repetirse.

B. Limpieza y normalización de los datos

Los registros crudos se depurarán en una secuencia de pasos. Primero se eliminarán las etiquetas HTML, los caracteres especiales y los espacios redundantes, y se unificará la codificación de texto. Luego se detectará el idioma de cada descripción y se conservarán únicamente las ofertas en español e inglés. Los duplicados se removerán en dos niveles: coincidencia exacta mediante la URL o un identificador de la oferta, y coincidencia aproximada mediante similitud de coseno entre descripciones, con el fin de descartar vacantes republicadas en distintos portales. Las ofertas observadas en varios barridos se consolidarán en un único registro, conservando sus fechas *first_seen* y *last_seen*.

Los títulos de puesto se normalizarán en dos dimensiones independientes. Por un lado, la familia ocupacional (por ejemplo, “Data Scientist” y “Científico de Datos” se agruparán bajo una misma familia). Por otro, el nivel de seniority (practicante, trainee, junior, semi-senior, senior y directivo), que se asignará mediante una jerarquía de reglas: primero, palabras clave presentes en el título; en su defecto, los años de experiencia solicitados en la descripción, extraídos con expresiones regulares y clasificados según umbrales de [años por nivel]; y, si ninguno de los dos criterios es concluyente, la oferta se etiquetará como nivel no especificado en lugar de descartarse. La asignación se validará sobre una muestra anotada manualmente. Separar ambas dimensiones evita que los modelos atribuyan a una habilidad un efecto salarial que en realidad se debe al nivel del puesto.

La variable salarial se convertirá a una única unidad de referencia (soles mensuales); los rangos se representarán por su punto medio y los valores atípicos se tratarán con el criterio del rango intercuartílico. Con esta variable se definirán las bandas salariales, que se obtendrán por cuantiles ([terciles/cuartiles]) para que las clases resulten balanceadas. Las ofertas de prácticas se excluirán de la definición de las bandas salariales y se analizarán por separado, dado que su remuneración corresponde a una subvención y no a un salario. Las ofertas sin salario declarado se conservarán para el análisis estructural del grafo, pero se excluirán del entrenamiento de los modelos supervisados. Además, se segmentarán las descripciones para aislar los apartados de requisitos y responsabilidades, que concentran las menciones a habilidades, y se descartarán los apartados de beneficios y de presentación de la empresa.

C. Extracción de habilidades mediante procesamiento de lenguaje natural

A partir del texto depurado se identificarán las habilidades técnicas mencionadas en cada oferta mediante un enfoque híbrido. En primer lugar, se construirá un catálogo de habilidades con sus alias y variantes (por ejemplo, “PowerBI” y “Power BI”), tomando como base una taxonomía abierta como ESCO y complementándola con términos propios del sector tecnológico. Este catálogo se aplicará sobre los textos, previa tokenización y lematización con *spaCy*, mediante reglas de coincidencia de frases. En segundo lugar, para capturar menciones que no aparecen literalmente en el catálogo, se recurrirá a un modelo de embeddings de oraciones que compare los fragmentos del texto con las habilidades del catálogo y asigne la más cercana cuando la similitud de coseno supere un umbral τ , en línea con los enfoques basados en *bi-encoders* propuestos por Decorte et al. (2025) para etiquetar habilidades.

Cada mención se normalizará a un identificador único de habilidad, de modo que variantes léxicas distintas se refieran al mismo nodo. Se descartarán las habilidades con una frecuencia inferior a $[n]$ ofertas para reducir el ruido. La calidad de la extracción se validará con una muestra aleatoria de $[N]$ ofertas anotadas manualmente, sobre la cual se calcularán precisión, exhaustividad y medida F1. El resultado de esta etapa será una matriz oferta–habilidad, que registra la presencia de cada habilidad en cada vacante.

D. Construcción del grafo heterogéneo de demanda laboral

Con la matriz oferta–habilidad y las bandas salariales se construirá un grafo heterogéneo ponderado $G = (V, E)$, cuyo conjunto de nodos incluirá tres tipos de entidades: ofertas laborales, habilidades y bandas salariales. Las aristas dirigidas oferta $\rightarrow$ habilidad representarán la relación “requiere”, y las aristas oferta $\rightarrow$ banda salarial representarán la pertenencia de cada vacante a su banda. Adicionalmente, se incorporarán aristas entre habilidades que aparecen juntas en una misma oferta, ponderadas por su frecuencia de co-ocurrencia, siguiendo la lógica de las redes de habilidades de Liu et al. [?]. Esta orientación de las aristas permite que, en la etapa siguiente, HITS interprete las ofertas como *hubs* y las habilidades como *authorities*. Cada oferta se representará como un nodo individual, sin agregarse por familia ocupacional: dos vacantes de un puesto similar, pero con habilidades o bandas salariales distintas, conservarán nodos y aristas propios. La familia ocupacional, el nivel de seniority y la fase de captura se almacenarán como atributos del nodo oferta, y los dos primeros se incorporarán como variables de entrada de los modelos supervisados.

El grafo se implementará con *NetworkX* y, de ser necesario por el volumen de datos, se persistirá en una base de datos de grafos como Neo4j. Para verificar su consistencia se calcularán estadísticos descriptivos como el número de nodos y aristas por tipo, la densidad, el grado medio y el número de componentes conexas. Los nodos de habilidad se diseñarán como el punto de unión con la rama académica: en las etapas posteriores se

conectarán a asignaturas, carreras y universidades, de modo que el grafo laboral pueda ampliarse sin reestructurarse.

E. Algoritmos de red: PageRank y HITS

Los algoritmos PageRank y HITS se aplican sobre el subgrafo de demanda para cuantificar la importancia estructural de cada habilidad. Este subgrafo se conforma por los nodos de vacantes y habilidades, con aristas dirigidas de requerimiento (extraídas mediante PLN desde los campos *requisitos* y *descripción*) y no dirigidas de co-ocurrencia. Se excluyen los nodos de *salario* y la rama académica para evitar fuga de información (*data leakage*) hacia los modelos supervisados y aislar la demanda pura del mercado.

PageRank asigna a cada competencia un puntaje de prestigio según su conectividad con habilidades centrales. Se calcula sobre la proyección ponderada por co-ocurrencia con amortiguamiento $\alpha = 0.85$ en NetworkX, evaluando su estabilidad con $\alpha \in \{0.70, 0.85, 0.95\}$ mediante la correlación de Spearman. HITS se aplica sobre las aristas dirigidas oferta $\rightarrow$ habilidad: la vacante recibe un puntaje de *hub* acorde a las competencias que exige en sus *requisitos*, y cada habilidad un puntaje de *authority* según la relevancia de las vacantes que la solicitan (ambos normalizados en $[0, 1]$).

Como referencia frente al conteo simple y grado, se calcula la centralidad de cercanía [?]. Finalmente, cada habilidad h se sintetiza en un índice de influencia estructural:

$$I(h) = \frac{\text{percentil}(PR_h) + \text{percentil}(Auth_h)}{2} \quad (1)$$

El vector resultante de métricas topológicas alimentará el diagnóstico curricular y los modelos predictivos posteriores.

F. Cálculo del índice de cobertura curricular

Este índice evalúa la alineación de los planes de estudio frente a las competencias más influyentes y mejor remuneradas del mercado laboral. La correspondencia semántica $m(a, h) \in [0, 1]$ se obtiene mediante la similitud de coseno entre los *embeddings* de la sumilla del curso a y la habilidad h , considerándose cubierta si $m(a, h) \geq \tau_c$ (umbral calibrado manualmente).

Cada habilidad recibe un peso integral $w(h) = \lambda I(h) + (1 - \lambda)S(h)$, donde $I(h)$ es el índice de influencia, $S(h) \in [0, 1]$ es la prima salarial normalizada y $\lambda = 0.5$. La prima $S(h)$ se estima mediante el coeficiente de presencia de h en una regresión hedónica sobre el logaritmo del *salario*, controlando por *ubicación*, *modalidad*, familia ocupacional (derivada del *título*) y *seniority* (obtenido de *requisitos* y *descripción*), aislando así el valor económico de la competencia.

El Índice de Cobertura Curricular para una carrera k se formula como:

$$ICC(k) = \frac{\sum_h w(h) \cdot c(k, h)}{\sum_h w(h)}, \quad \text{con } c(k, h) = \max_{a \in k} m(a, h) \cdot \mathbb{I}(m(a, h) \geq \tau_c) \quad (2)$$

El *ICC* se computa a nivel de curso, carrera e institución, complementándose con un listado de brechas priorizadas (K habilidades de mayor peso con $c(k, h) = 0$). Se valida sobre M pares anotados (precisión, exhaustividad y F_1), realizando

análisis de sensibilidad sobre τ_c y λ , y contrastándolo contra una versión no ponderada ($w(h) = 1$) [?]. El indicador refleja la cobertura del plan de estudios y no el aprendizaje efectivo.

G. Modelos de aprendizaje automático: clasificación salarial y clustering

Ambas tareas operan sobre una matriz unificada construida con los datos raspados: (i) controles (*ubicación, modalidad, familia ocupacional vía título, y seniority* y experiencia extraídos de *requisitos y descripción*); (ii) presencia vectorial de habilidades; (iii) métricas de red (*hub* de la oferta, media, máximo y suma de PageRank y *authority*); y (iv) cobertura curricular ponderada de la vacante.

Para la **clasificación salarial**, la variable objetivo son las bandas salariales (cuantiles balanceados del *salario* mensual declarado, excluyendo prácticas y salarios no especificados). Se entrenan Regresión Logística Multinomial, Random Forest y XGBoost mediante validación cruzada estratificada de k pliegues y validación temporal. Para evitar fuga de información, $S(h)$ se recalcula estrictamente dentro de cada partición de entrenamiento. Se reportan Exactitud, F_1 -macro, Kappa cuadrático ponderado y error a ± 1 banda. La contribución de variables se mide mediante ablación, importancia por permutación y valores SHAP, caracterizando además el sesgo de selección de las ofertas con salario visible.

En el **clustering**, se integran todas las ofertas (con o sin salario declarado). Cada vacante se representa mediante su vector de habilidades ponderado por $I(h)$, reducido con TruncatedSVD. Se implementan K-Means y Clustering Jerárquico (enlace de Ward), optimizando el número de conglomerados con el coeficiente de silueta y el índice de Davies–Bouldin, y validando su estabilidad mediante remuestreo *bootstrap* y el Índice de Rand Ajustado (ARI). Los grupos se caracterizan según sus competencias dominantes, distribución de *modalidad, ubicación* y cobertura curricular, contrastándolos con las familias del *título* mediante ARI e Información Mutua Normalizada (NMI).

H. Dashboard integral: mercado laboral y diagnóstico curricular

Los resultados se integran en una aplicación interactiva desarrollada en Python con Streamlit y Plotly, conectada a los artefactos analíticos de las etapas previas y dividida en dos módulos:

- **Módulo de mercado laboral:** Muestra el ranking de habilidades por PageRank, *authority*, prima salarial $S(h)$ y frecuencia de mención en *requisitos y descripción*. Integra un grafo interactivo de habilidades (tamaño por PageRank y color por cluster), distribuciones de bandas salariales cruzadas por familia ocupacional, *seniority, modalidad y ubicación*, y un simulador salarial que predice la banda probable y estima los valores SHAP locales a partir de atributos seleccionados. Filtros dinámicos permiten segmentar por portal (*Indeed* o *Computrabajo*), fecha, *modalidad* y región geográfica.

- **Módulo de diagnóstico curricular:** Despliega el índice *ICC* por universidad, carrera y asignatura; un mapa de calor entre programas y habilidades críticas $w(h)$; la matriz priorizada de brechas formativas; y un explorador relacional bidireccional para consultar en qué asignaturas se imparte una habilidad o qué competencias de mercado omite un plan de estudios específico.

La usabilidad se evaluará con estudiantes y coordinadores académicos mediante la escala SUS (*System Usability Scale*). Las vistas presentan datos agregados y anonimizados, incorporando notas metodológicas sobre el periodo de recolección y las limitaciones por el sesgo de ofertas sin salario declarado.

V. PREPARE YOUR PAPER BEFORE STYLING

Before you begin to format your paper, first write and save the content as a separate text file. Complete all content and organizational editing before formatting. Please note sections V-A–V-E below for more information on proofreading, spelling and grammar.

Keep your text and graphic files separate until after the text has been formatted and styled. Do not number text heads— $\text{\LaTeX}$ will do that for you.

A. Abbreviations and Acronyms

Define abbreviations and acronyms the first time they are used in the text, even after they have been defined in the abstract. Abbreviations such as IEEE, SI, MKS, CGS, ac, dc, and rms do not have to be defined. Do not use abbreviations in the title or heads unless they are unavoidable.

B. Units

- Use either SI (MKS) or CGS as primary units. (SI units are encouraged.) English units may be used as secondary units (in parentheses). An exception would be the use of English units as identifiers in trade, such as “3.5-inch disk drive”.
- Avoid combining SI and CGS units, such as current in amperes and magnetic field in oersteds. This often leads to confusion because equations do not balance dimensionally. If you must use mixed units, clearly state the units for each quantity that you use in an equation.
- Do not mix complete spellings and abbreviations of units: “Wb/m²” or “webers per square meter”, not “webers/m²”. Spell out units when they appear in text: “. . . a few henries”, not “. . . a few H”.
- Use a zero before decimal points: “0.25”, not “.25”. Use “cm³”, not “cc”).

C. Equations

Number equations consecutively. To make your equations more compact, you may use the solidus (/), the exp function, or appropriate exponents. Italicize Roman symbols for quantities and variables, but not Greek symbols. Use a long dash rather than a hyphen for a minus sign. Punctuate equations with commas or periods when they are part of a sentence, as in:

$$a + b = \gamma \quad (3)$$

Be sure that the symbols in your equation have been defined before or immediately following the equation. Use “(3)”, not “Eq. (3)” or “equation (3)”, except at the beginning of a sentence: “Equation (3) is . . .”

D. *L^AT_EX-Specific Advice*

Please use “soft” (e.g., `\eqref{Eq}`) cross references instead of “hard” references (e.g., (1)). That will make it possible to combine sections, add equations, or change the order of figures or citations without having to go through the file line by line.

Please don’t use the `{eqnarray}` equation environment. Use `{align}` or `{IEEEeqnarray}` instead. The `{eqnarray}` environment leaves unsightly spaces around relation symbols.

Please note that the `{subequations}` environment in *L^AT_EX* will increment the main equation counter even when there are no equation numbers displayed. If you forget that, you might write an article in which the equation numbers skip from (17) to (20), causing the copy editors to wonder if you’ve discovered a new method of counting.

BIB_TE_X does not work by magic. It doesn’t get the bibliographic data from thin air but from .bib files. If you use *BIB_TE_X* to produce a bibliography you must send the .bib files.

L^AT_EX can’t read your mind. If you assign the same label to a subsection and a table, you might find that Table I has been cross referenced as Table IV-B3.

L^AT_EX does not have precognitive abilities. If you put a `\label` command before the command that updates the counter it’s supposed to be using, the label will pick up the last counter to be cross referenced instead. In particular, a `\label` command should not go before the caption of a figure or a table.

Do not use `\nonumber` inside the `{array}` environment. It will not stop equation numbers inside `{array}` (there won’t be any anyway) and it might stop a wanted equation number in the surrounding equation.

E. *Some Common Mistakes*

- The word “data” is plural, not singular.
- The subscript for the permeability of vacuum μ_0 , and other common scientific constants, is zero with subscript formatting, not a lowercase letter “o”.
- In American English, commas, semicolons, periods, question and exclamation marks are located within quotation marks only when a complete thought or name is cited, such as a title or full quotation. When quotation marks are used, instead of a bold or italic typeface, to highlight a word or phrase, punctuation should appear outside of the quotation marks. A parenthetical phrase or statement at the end of a sentence is punctuated outside of the closing parenthesis (like this). (A parenthetical sentence is punctuated within the parentheses.)
- A graph within a graph is an “inset”, not an “insert”. The word alternatively is preferred to the word “alternately” (unless you really mean something that alternates).

- Do not use the word “essentially” to mean “approximately” or “effectively”.
- In your paper title, if the words “that uses” can accurately replace the word “using”, capitalize the “u”; if not, keep using lower-cased.
- Be aware of the different meanings of the homophones “affect” and “effect”, “complement” and “compliment”, “discreet” and “discrete”, “principal” and “principle”.
- Do not confuse “imply” and “infer”.
- The prefix “non” is not a word; it should be joined to the word it modifies, usually without a hyphen.
- There is no period after the “et” in the Latin abbreviation “et al.”.
- The abbreviation “i.e.” means “that is”, and the abbreviation “e.g.” means “for example”.

An excellent style manual for science writers is [9].

F. *Authors and Affiliations*

The class file is designed for, but not limited to, six authors. A minimum of one author is required for all conference articles. Author names should be listed starting from left to right and then moving down to the next line. This is the author sequence that will be used in future citations and by indexing services. Names should not be listed in columns nor group by affiliation. Please keep your affiliations as succinct as possible (for example, do not differentiate among departments of the same organization).

G. *Identify the Headings*

Headings, or heads, are organizational devices that guide the reader through your paper. There are two types: component heads and text heads.

Component heads identify the different components of your paper and are not topically subordinate to each other. Examples include Acknowledgments and References and, for these, the correct style to use is “Heading 5”. Use “figure caption” for your Figure captions, and “table head” for your table title. Run-in heads, such as “Abstract”, will require you to apply a style (in this case, italic) in addition to the style provided by the drop down menu to differentiate the head from the text.

Text heads organize the topics on a relational, hierarchical basis. For example, the paper title is the primary text head because all subsequent material relates and elaborates on this one topic. If there are two or more sub-topics, the next level head (uppercase Roman numerals) should be used and, conversely, if there are not at least two sub-topics, then no subheads should be introduced.

H. *Figures and Tables*

a) *Positioning Figures and Tables:* Place figures and tables at the top and bottom of columns. Avoid placing them in the middle of columns. Large figures and tables may span across both columns. Figure captions should be below the figures; table heads should appear above the tables. Insert

TABLE I
TABLE TYPE STYLES

Table Head	Table Column Head		
	Table column subhead	Subhead	Subhead
copy	More table copy ^a		

^aSample of a Table footnote.

figures and tables after they are cited in the text. Use the abbreviation “Fig.”, even at the beginning of a sentence.

Figure Labels: Use 8 point Times New Roman for Figure labels. Use words rather than symbols or abbreviations when writing Figure axis labels to avoid confusing the reader. As an example, write the quantity “Magnetization”, or “Magnetization, M”, not just “M”. If including units in the label, present them within parentheses. Do not label axes only with units. In the example, write “Magnetization (A/m)” or “Magnetization {A[m(1)]}”, not just “A/m”. Do not label axes with a ratio of quantities and units. For example, write “Temperature (K)”, not “Temperature/K”.

ACKNOWLEDGMENT

The preferred spelling of the word “acknowledgment” in America is without an “e” after the “g”. Avoid the stilted expression “one of us (R. B. G.) thanks ...”. Instead, try “R. B. G. thanks...”. Put sponsor acknowledgments in the unnumbered footnote on the first page.

REFERENCES

Please number citations consecutively within brackets [3]. The sentence punctuation follows the bracket [4]. Refer simply to the reference number, as in [5]—do not use “Ref. [5]” or “reference [5]” except at the beginning of a sentence: “Reference [5] was the first ...”

Number footnotes separately in superscripts. Place the actual footnote at the bottom of the column in which it was cited. Do not put footnotes in the abstract or reference list. Use letters for table footnotes.

Unless there are six authors or more give all authors’ names; do not use “et al.”. Papers that have not been published, even if they have been submitted for publication, should be cited as “unpublished” [6]. Papers that have been accepted for publication should be cited as “in press” [7]. Capitalize only the first word in a paper title, except for proper nouns and element symbols.

For papers published in translation journals, please give the English citation first, followed by the original foreign-language citation [8].

REFERENCES

- [1] Z. Liu, J. M. Clarke, B. Rohenkohl, and M. Barahona, “Patterns of co-occurrent skills in UK job adverts,” *PLOS Complex Syst.*, vol. 2, no. 2, p. e0000028, Feb. 2025, doi: 10.1371/journal.pcsy.0000028.
- [2] K. V. Ampolu, U. Mogili, P. Kavva, G. Roja, V. Hema, J. Suresh, M. Siva, and B. A. Kumar, “Web based syllabus to skill mapping system using machine learning and natural language processing,” *Int. J. Innov. Res. Technol.*, vol. 12, no. 11, pp. 391–398, Apr. 2026.

- [3] G. Eason, B. Noble, and I. N. Sneddon, “On certain integrals of Lipschitz-Hankel type involving products of Bessel functions,” *Phil. Trans. Roy. Soc. London*, vol. A247, pp. 529–551, April 1955.
- [4] J. Clerk Maxwell, *A Treatise on Electricity and Magnetism*, 3rd ed., vol. 2. Oxford: Clarendon, 1892, pp.68–73.
- [5] I. S. Jacobs and C. P. Bean, “Fine particles, thin films and exchange anisotropy,” in *Magnetism*, vol. III, G. T. Rado and H. Suhl, Eds. New York: Academic, 1963, pp. 271–350.
- [6] K. Elissa, “Title of paper if known,” unpublished.
- [7] R. Nicole, “Title of paper with only first word capitalized,” *J. Name Stand. Abbrev.*, in press.
- [8] Y. Yorozu, M. Hirano, K. Oka, and Y. Tagawa, “Electron spectroscopy studies on magneto-optical media and plastic substrate interface,” *IEEE Transl. J. Magn. Japan*, vol. 2, pp. 740–741, August 1987 [Digests 9th Annual Conf. Magnetism Japan, p. 301, 1982].
- [9] M. Young, *The Technical Writer’s Handbook*. Mill Valley, CA: University Science, 1989.

IEEE conference templates contain guidance text for composing and formatting conference papers. Please ensure that all template text is removed from your conference paper prior to submission to the conference. Failure to remove the template text from your paper may result in your paper not being published.