

# PageRank y Minería de Grafos Heterogéneos sobre Habilidades Laborales y Mallas Universitarias: Un Enfoque de Analítica Web para la Predicción Salarial y el Diagnóstico de Brechas Formativas

**Fernández, Rodrigo**

Facultad de Ingeniería  
Universidad del Pacífico  
Lima, Perú

*ra.fernandezzy@alum.up.edu.pe*

**Rojas, Priscila**

Facultad de Ingeniería  
Universidad del Pacífico  
Lima, Perú

*pc.rojassu@alum.up.edu.pe*

**Tirado, Mario**

Facultad de Ingeniería  
Universidad del Pacífico  
Lima, Perú

*mp.tiradom@alum.up.edu.pe*

***Index Terms*—PageRank, HITS, grafos heterogéneos, analítica web, minería de datos laborales, brecha formativa, predicción salarial**

## I. INTRODUCCIÓN

En los últimos años, la rápida evolución de la industria tecnológica y los procesos de digitalización han transformado drásticamente la demanda de competencias en el mercado de trabajo. En este contexto, la Analítica Web y la minería de datos no estructurados (Web Content Mining) se han consolidado como herramientas clave para estudiar la dinámica laboral a partir de vacantes publicadas en portales de empleo en línea. Diversas investigaciones han recurrido a técnicas de procesamiento de lenguaje natural y modelos de aprendizaje automático para estructurar ofertas y clasificar compensaciones económicas, empleando de forma paralela el análisis de redes complejas para evaluar la relevancia y conectividad de habilidades técnicas clave dentro del ecosistema laboral.

A pesar de estos avances, persiste una fragmentación metodológica fundamental: la demanda laboral y la oferta académica universitaria suelen investigarse de forma aislada. Por un lado, los postulantes y egresados enfrentan una marcada asimetría de información que les dificulta identificar con precisión qué competencias específicas determinan mejores bandas salariales en el mercado profesional. Por otro lado, no se dispone de marcos computacionales basados en la web que contrasten directamente los requerimientos salariales con los planes de estudio y sumillas de las universidades. Permanece sin resolver cómo mapear de manera sistemática y automatizada en qué facultades, carreras o asignaturas se adquieren las competencias de mayor impacto estructural, dejando sin cuantificar la brecha formativa entre las aulas universitarias y las demandas reales del mercado.

Para abordar esta brecha, el presente estudio plantea una arquitectura de Analítica Web sustentada en la minería de grafos heterogéneos que articula ofertas laborales, competencias técnicas y programas curriculares universitarios. La metodología contempla la extracción web automatizada de

ofertas laborales en el sector tecnológico y de planes de estudio universitarios, normalizando sus descriptores técnicos mediante técnicas de procesamiento de lenguaje natural. Sobre la red heterogénea resultante se aplican algoritmos de centralidad de enlaces (PageRank y HITS) para ponderar el impacto sistémico de cada competencia, integrando estas métricas en modelos de aprendizaje supervisado para la predicción de bandas salariales y en algoritmos de agrupamiento para clasificar familias de puestos. En paralelo, se formula un índice de cobertura curricular diseñado para evaluar el grado de alineación de las mallas universitarias frente a las habilidades más influyentes y mejor remuneradas del mercado.

## II. TRABAJOS RELACIONADOS

La literatura reciente aborda principalmente dos componentes del problema: la relación entre habilidades y salarios, y la correspondencia entre las competencias demandadas por el mercado laboral y la formación universitaria.

En el primer componente, Ji, Sun y Zhu [1] desarrollaron LGDESetNet, un modelo explicable que utiliza un grafo de habilidades para predecir salarios e identificar las combinaciones de competencias con mayor influencia sobre la remuneración. Esta investigación se relaciona con el presente proyecto porque demuestra que las habilidades no deben analizarse como elementos aislados, sino como una red de competencias que se complementan y adquieren distinto valor dentro del mercado laboral. Sin embargo, su análisis se limita al ámbito laboral y no determina si las competencias mejor remuneradas se desarrollan en los programas universitarios.

Desde la perspectiva académica, Kendzia, Linder y Barthelmess [2] compararon la evolución de la demanda de habilidades en inteligencia artificial con la capacidad de respuesta de las universidades suizas. Mediante el análisis de millones de ofertas laborales y la información recopilada de instituciones de educación superior, identificaron que la demanda de profesionales especializados aumentó con mayor rapidez que la oferta formativa. Este estudio evidencia la existencia de una brecha entre las competencias solicitadas por las empresas

y aquellas desarrolladas por las universidades, aunque no construye una red que permita localizar las carreras, cursos o asignaturas en las que debería fortalecerse cada habilidad.

Ambas investigaciones coinciden en utilizar información del mercado laboral para identificar competencias relevantes, pero analizan partes diferentes del problema: la primera aporta el componente de valoración económica de las habilidades y la segunda aporta el componente de alineación curricular. A pesar de estos aportes, todavía falta un enfoque que integre ambos componentes dentro de un mismo modelo.

Por su parte, Liu et al. [3] analizaron 65 millones de ofertas laborales mediante una red de co-ocurrencia de habilidades y técnicas de centralidad topológica, hallando que las competencias con menor centralidad de cercanía corresponden a perfiles especializados asociados a una mayor prima salarial ( $\rho = -0,51$ ). Este trabajo respalda la modelación del mercado laboral mediante grafos de habilidades y fundamenta la hipótesis de que la posición estructural de una competencia en la red incide en la remuneración.

Ampolu et al. [4] implementaron un sistema basado en procesamiento de lenguaje natural y similitud de coseno para extraer términos clave de sílabos universitarios y contrastarlos contra competencias requeridas por la industria, cuantificando brechas formativas. Este antecedente respalda el componente temático de alineamiento curricular del presente proyecto, aunque pone en evidencia las limitaciones del cotejo léxico estático, justificando la necesidad de un grafo dinámico priorizado por algoritmos de prestigio estructural como PageRank y HITS.

Beresewicz, Cherniaiev, Mantaj y Pater [5] estudian el desajuste entre la formación educativa y la demanda del mercado laboral usando ofertas de empleo en línea, recolectando cerca de 40 millones de ofertas en Polonia (2017–2019) y comparándolas con la oferta de trabajadores estimada mediante encuesta. Encontraron que el mayor desajuste se da en habilidades específicas de cada puesto. Sin embargo, el lado de la oferta se estima con una encuesta y no con los planes de estudio, y el emparejamiento de texto se basa en diccionarios, limitación que los propios autores reconocen.

Decorte et al. [6] abordan la extracción de habilidades en ofertas laborales mediante ConTeXT-match, un bi-encoder con aprendizaje contrastivo diseñado para clasificar habilidades contra el catálogo ESCO, alcanzando resultados competitivos con un modelo liviano y escalable. Su alcance se limita al texto de las ofertas: tratan las habilidades como etiquetas aisladas, sin medir su relación con el salario ni su vínculo con la formación universitaria.

A diferencia de los antecedentes, esta propuesta integra demanda laboral y oferta formativa en un grafo heterogéneo donde la habilidad conecta ofertas con asignaturas, carreras y universidades, usando los planes de estudio y no una encuesta. Sobre ese grafo, PageRank y HITS miden el impacto sistémico de cada habilidad, y esas métricas alimentan modelos de predicción de bandas salariales y de agrupamiento de puestos. Finalmente, un índice de cobertura curricular permite diagnosticar la brecha a nivel de asignatura y carrera.

### III. METODOLOGÍA

La metodología se organiza en una arquitectura secuencial de ocho etapas, ilustrada en la Fig. 1.




Figura 1. Diagrama de flujo metodológico: diseño convergente desde la extracción de datos no estructurados hasta el modelado analítico y predictivo.

#### III-A. Extracción web de ofertas laborales

Se recolectarán ofertas laborales del sector tecnológico publicadas en portales de empleo de acceso público en Perú, priorizando Computrabajo para el alcance inicial del proyecto e incorporando Indeed como extensión. La extracción se implementará en Python con `requests` y `BeautifulSoup` para páginas estáticas, y con `Playwright` para contenido cargado dinámicamente. Las consultas se construirán a partir de palabras clave asociadas a roles tecnológicos (desarrollo de software, ciencia de datos, ingeniería de datos, DevOps, ciberseguridad).

La recolección se divide en dos fases. En la fase retrospectiva, el primer barrido captura las ofertas aún activas publicadas dentro de los 30 días previos. En la fase prospectiva, el barrido se repite cada 3 días durante 7 semanas, en el cronograma proyectado del 28 de septiembre al 1 de noviembre, con el fin de captar ofertas nuevas y registrar cuándo dejan de estar visibles. Dado que la fase retrospectiva sobrerrepresenta las vacantes de mayor duración, este sesgo se documentará explícitamente como limitación del estudio, reportando los resultados de ambas fases por separado para que el sesgo sea auditable.

Para cada vacante se almacenarán título, empresa, descripción completa, ubicación, modalidad, nivel de experiencia, rango salarial declarado, fecha de publicación, URL de origen, y las variables de control `first_seen`, `last_seen` y fase de captura. Cada registro se guardará sin modificaciones en formato JSON.

### III-B. Limpieza y normalización de los datos

Los registros crudos se depurarán eliminando etiquetas HTML, caracteres especiales y espacios redundantes. Los duplicados se removerán en dos niveles: coincidencia exacta por URL, y coincidencia aproximada por similitud de coseno entre descripciones. Los títulos de puesto se normalizarán en dos dimensiones independientes: familia ocupacional y nivel de seniority (asignado mediante palabras clave en el título y, en su defecto, años de experiencia extraídos con expresiones regulares).

La variable salarial se convertirá a soles mensuales. En lugar de colapsar cada rango a su punto medio, se explorará una **regresión con datos censurados por intervalo**, que reconoce que un rango declarado (por ejemplo, S/ 3000–4000) conlleva incertidumbre real y no un valor puntual. Las bandas salariales se definirán por cuantiles para clases balanceadas. Dado que una proporción relevante de ofertas en el mercado peruano no declara salario, se estimará la proporción exacta en la primera semana de recolección y, de ser significativa, se incorporará una corrección de sesgo de selección (tipo Heckman) para evitar que las bandas salariales estén distorsionadas por qué empresas publican cifra y cuáles no.

### III-C. Extracción de habilidades mediante procesamiento de lenguaje natural

Se construirá un catálogo de habilidades con sus alias y variantes, tomando como base una taxonomía abierta como ESCO. Este catálogo se aplicará sobre los textos, previa tokenización y lematización con `spaCy`, mediante reglas de coincidencia de frases; el matching por embeddings de oraciones se incorporará como extensión para capturar menciones no literales. La calidad de la extracción se validará con una muestra anotada manualmente, calculando precisión, exhaustividad, medida F1 y **kappa de Cohen** entre anotadores para garantizar consistencia del criterio de etiquetado.

### III-D. Construcción del grafo heterogéneo de demanda laboral

Se construirá un grafo heterogéneo ponderado  $G = (V, E)$  con tres tipos de nodos: ofertas laborales, habilidades y bandas salariales. Las aristas dirigidas oferta  $\rightarrow$  habilidad representan la relación “requiere”. Las aristas entre habilidades que co-ocurren en una misma oferta se ponderarán mediante **información mutua puntual (PMI)** en lugar de frecuencia cruda, de modo que habilidades genéricas (“comunicación”, “trabajo en equipo”) no dominen el grafo solo por su frecuencia de aparición. El grafo se implementará con `NetworkX`.

### III-E. Algoritmos de red: PageRank y HITS

PageRank se calcula sobre la proyección ponderada por co-ocurrencia con amortiguamiento  $\alpha = 0,85$ , evaluando su estabilidad con  $\alpha \in \{0,70, 0,85, 0,95\}$ . HITS se aplica sobre las aristas dirigidas oferta  $\rightarrow$  habilidad. Además del análisis de sensibilidad de  $\alpha$ , se evaluará la sensibilidad del umbral de similitud  $\tau$  usado en el matching por embeddings (Sección III-C), dado que también puede alterar significativamente la topología resultante. Cada habilidad  $h$  se sintetiza en un índice de influencia estructural:

$$I(h) = \frac{\text{percentil}(PR_h) + \text{percentil}(Auth_h)}{2} \quad (1)$$

### III-F. Cálculo del índice de cobertura curricular

Este índice evalúa la alineación de los planes de estudio frente a las competencias más influyentes del mercado laboral. La correspondencia semántica  $m(a, h) \in [0, 1]$  se obtiene mediante similitud de coseno (TF-IDF) entre la sumilla del curso  $a$  y la habilidad  $h$ , considerada cubierta si  $m(a, h) \geq \tau_c$ . Cada habilidad recibe un peso integral  $w(h) = \lambda I(h) + (1 - \lambda) S(h)$ , donde  $S(h)$  es la prima salarial normalizada y  $\lambda = 0,5$ . El Índice de Cobertura Curricular para una carrera  $k$  se formula como:

$$ICC(k) = \frac{\sum_h w(h) \cdot c(k, h)}{\sum_h w(h)} \quad (2)$$

donde  $c(k, h) = \max_{a \in k} m(a, h) \cdot \mathbb{I}(m(a, h) \geq \tau_c)$ . El umbral  $\tau_c$  se calibrará y validará contra un panel de 2-3 coordinadores académicos que etiqueten manualmente si una sumilla cubre realmente una habilidad, evitando que  $\tau_c$  sea un valor arbitrario. Para el alcance inicial, el ICC se calculará sobre las carreras y sílabos públicos de la Universidad del Pacífico.

### III-G. Modelos de aprendizaje automático

Para la **clasificación salarial**, se entrenarán Random Forest y, como extensión, XGBoost, mediante validación cruzada estratificada. Se incluirá como **baseline** el método de similitud léxica estática propuesto por Ampolu et al. [4], de modo que la mejora aportada por las métricas de red (PageRank, HITS) quede demostrada empíricamente y no solo argumentada. Se reportarán exactitud, F1-macro y error  $\pm 1$  banda, prestando atención al desbalance de clases en las bandas salariales extremas. En el **clustering**, se implementará K-Means sobre el vector de habilidades ponderado por  $I(h)$ .

### III-H. Dashboard integral

Los resultados se integrarán en una aplicación en Streamlit con un módulo de mercado laboral (ranking de habilidades por PageRank, distribuciones salariales) y un módulo de diagnóstico curricular (índice ICC por carrera y asignatura, mapa de brechas formativas).

#### IV. CONCLUSIONES PRELIMINARES

Este proyecto propone un marco computacional que, a diferencia de los antecedentes revisados, integra en un mismo grafo heterogéneo la demanda laboral y la oferta formativa universitaria, permitiendo no solo identificar qué habilidades están mejor remuneradas sino también dónde se enseñan y con qué profundidad. El núcleo mínimo viable –grafo, PageRank/HITS e índice de cobertura curricular– responde por sí solo a la pregunta de investigación planteada, mientras que los modelos predictivos y el dashboard completo constituyen extensiones naturales del trabajo.

#### REFERENCIAS

- [1] Y. Ji, Y. Sun, and H. Zhu, “Enhancing job salary prediction with disentangled composition effect modeling: A neural prototyping approach,” *Frontiers of Computer Science*, 2025.
- [2] M. J. Kendzia, L. Linder, and P. Barthelmess, “The rise of AI careers and curricular shifts in Swiss higher education,” *Social Sciences & Humanities Open*, vol. 12, p. 102059, 2025.
- [3] Z. Liu, J. M. Clarke, B. Rohenkohl, and M. Barahona, “Patterns of co-occurrent skills in UK job adverts,” *PLOS Complex Syst.*, vol. 2, no. 2, p. e0000028, Feb. 2025.
- [4] K. V. Ampolu, U. Mogili, P. Kavya, G. Roja, V. Hema, J. Suresh, M. Siva, and B. A. Kumar, “Web based syllabus to skill mapping system using machine learning and natural language processing,” *Int. J. Innov. Res. Technol.*, vol. 12, no. 11, pp. 391–398, Apr. 2026.
- [5] M. Beresewicz, D. Cherniaiev, R. Mantaj, and R. Pater, “Mismatch between labour demand and supply using online job vacancy data,” 2024.
- [6] J.-T. Decorte et al., “ConTeXT-match: Contrastive token-level matching for skill extraction,” 2025.